Plants in ECNU 文件目录

Plants in ECNU 文件目录

data

数据获取与分析部分

statmodel

机器学习模型部分

culture

数据分析 - 自然语言处理 - 文化关键词

ana_emo

数据分析 - 自然语言处理 - 领养寄语情感分析

wordcloud

数据可视化 - 寄语词云

datavis

数据可视化 - 图表可视化

prototype

网页原型设计

login

登录数据库

ECNU-in-Plants

网页端代码

data

数据获取与分析部分

- `all_trees.json`，所有植物的信息（不含template中的长文本）
- `all_templates.json`，所有植物类型templates的详细信息（包含长文本）
- `all_trees_for_lib.json`，添加植物文化关键词"key_phrase"、领养人信息"hasOwner"、领养记录更新时间"ownerTime"的所有植物信息
- `notes_charles.md`，关于charles的使用备忘&获取到的有用url
- `notes_data_structure.md`，描述了`all_trees.json`和`all_templates.json`的数据结构及各个字段含义
- icon
  - => 存放植物图标图片的文件夹
  - 里面每个文件的名称都是`xxx.jpg`，命名同icon字段中url内图片的名称
- get_data_code
  - => 获取植物信息的爬虫代码

    - `get_trees_data.py`，爬取植物信息的代码，其结果为 `all_trees.json`
    - `get_templates_data.py`，在 `get_trees_data.py` 的基础上爬取植物信息的代码，其结果为 `all_templates.json`
- get_icon_code
    - => 获取植物图标的代码
    - `get_icon.ipynb`，从 `all_templates.json` 中获取icon字段url并保存为 `icon.json` 的代码
    - `icon.json`，存放了植物图标的url
    - `icon.txt`，对 `icon.json` 进行修改以用于下载的代码

statmodel

机器学习模型部分

- => 用来预测下一棵最有可能被领养的树
    - reg
        - => 使用logistics回归模型
        - `pred_tree_reg.ipynb`，模型代码，使用aic筛选变量，逻辑回归拟合。
        - `pred_tree_reg.csv`，便于用excel查看的结果。
        - `pred_result_reg.json`，便于用于网页的结果。**pred_1**表示被领养的概率。
    - svm
        - => 使用SVM分类模型
        - `pred_tree_svm.ipynb`，模型代码，使用支持向量机进行分类，训练比例为0.7，样本权重为{1:10}。对模型的评估包括准确率（训练0.75，测试0.73）、召回率（1）、混淆矩阵、ROC曲线、AUC值（0.99）、最佳阈值Youden Index（0.996836）。
            - 训练集上的混淆矩阵为

$$\begin{array}{cc} & \text{预测值} \quad 0 \qquad 1 \\ \text{真实值} & \begin{array}{c} 0 \\ 1 \end{array} \begin{bmatrix} 106 & 2 \\ 515 & 1460 \end{bmatrix} \end{array}$$

            - 测试集上的混淆矩阵为

$$\begin{array}{cc} & \text{预测值} \quad 0 \qquad 1 \\ \text{真实值} & \begin{array}{c} 0 \\ 1 \end{array} \begin{bmatrix} 49 & 0 \\ 245 & 599 \end{bmatrix} \end{array}$$

        - `pred_tree_svm.csv`，便于用excel查看的结果。

- `pred_result_svm.json`，便于用于网页的结果。**pred**表示被预测为领养还是不领养，**pred_1**表示被领养的概率。

> （1）筛选所有未被认养的（ `owner` 取值为0）
>
> （2）【可选】根据用户条件再筛选，如校区 `place` 、植物品种 `template` 、植物习性 `habit`
>
> （3）被认养概率 `pre_1` 取值最大的，或者在 `pred` 取值为1的那些里random

culture

数据分析 - 自然语言处理 - 文化关键词

ana_emo

数据分析 - 自然语言处理 - 领养寄语情感分析

- raw_data
  - => 用于情感分析的源数据
  - `data.xlsx`， 每棵植物上的题词与留言
- code
  - => 调用讯飞星火大模型的Python接口，针对raw_data文件夹下的数据进行情感分析
  - `xlsx_processing.py`，对 `data.xlsx` 进行数据清洗
  - `SparkApi.py`，大模型api
  - `main.py`，调用api对清洗后的数据进行情感分析
  - `__pycache__` 文件夹，大模型内核
- res
  - => 数据处理后的结果
  - `test.xlsx`，`xlsx.processing.py` 处理后的数据
  - `new_test.xlsx`，添加了情感分析后的数据

wordcloud

数据可视化 - 寄语词云

datavis

数据可视化 - 图表可视化

- => 数据可视化
- sankey
  - => 桑基图，展示认养植物所属学院&植物类型
  - `sankey.ipynb`，用于生成桑基图的python代码
  - `sankey.html`，生成的桑基图html
  - `data_for_sankey.json`，用于sankey图数据可视化，里面是手动修改过学院的所有owner数据
- sunburst
  - => 旭日图，展示校内登记的植物分布
  - `sunburst.ipynb`，用于生成旭日图所需数据
  - `sunburst.html`，定义旭日图
  - `data_for_sunburst.json`，用于sunburst图数据可视化
- parallel
  - => 平行坐标轴，展示校内植物的高度、胸径等维度数据
  - `parallel.ipynb`，用于生成平行坐标轴的python代码
  - `parallel.html`，生成的平行坐标轴html

prototype

网页原型设计

login

登录数据库

ECNU-in-Plants

网页端代码